

AITP: AI 理论物理学家研究协议

理论物理方向的约束工程思想

贾博涵

中国科学院物理研究所

中国科学院物理研究所

2026 年 4 月

报告大纲


- ① 动机：为什么需要 AITP
- ② AITP 架构设计
- ③ 研究实践
- ④ 实例与项目进展
- ⑤ 展望与总结

大语言模型 (LLM) 的能力

- 可以写出物理风格的文本
- 可以进行符号推导
- 可以阅读论文、生成综述
- 可以辅助数值计算

但有一个根本性问题：

流畅 $\neq$ 理解 (Fluency $\neq$ Understanding)
自信 $\neq$ 正确 (Confidence $\neq$ Truth)



*“The goal is not fluency.
The goal is disciplined participation
in the search for truth.”*

AI 辅助理论物理的根本失效模式

- ① 将**流畅性**等同于**理解力**
- ② 将**自信**等同于**正确性**
- ③ 将**语言层面的合理性**等同于**科学上的有效性**
- ④ **不确定性**被压平为虚假的闭环结论

**我们需要的不只是一个更好的提示词 (prompt),
而是一套受治理的研究协议 (protocol)。**

约束工程 (Harness Engineering)


核心思想：约束边界，而非内部思考。

一个好的**安全带 (harness)**：

- ✓ 引导方向 (steer)
- ✓ 记忆历史 (remember)
- ✓ 验证结果 (validate)
- ✓ 积累知识 (compound)
- ✗ **不替代大脑** (not replace the brain)

AITP 的定位

强约束 + 保留模型自由度 +
显式证据纪律 + 持久记忆



AITP 是什么？

定义

AITP = Superpowers 交互层 + 分层研究内核 + 原生 Agent 执行能力

AITP 不是：

- ✗ 一个聊天机器人
- ✗ 一组提示词模板
- ✗ 一个“物理学家人格”
- ✗ 论文自动生成器

AITP 是：

- ✓ 受治理的研究协议
- ✓ 可审计、可恢复、可复用
- ✓ 分层的证据管线
- ✓ 人机协作研究框架

Charter above runtime. Protocol above heuristics.

Agent 是执行者，不是真理的来源。

五层架构 (L0-L4)

L2 被
各层
查询



L0 源获取层 (Source Acquisition) 论文 笔记 代码 引用图


L1 暂定理解层 (Provisional Understanding) 分析笔记 推导草图 概念结构

L3 探索输出层 (Exploratory Output) 候选声明 猜想 草稿 负面结果

L4 验证裁决层 (Validation & Adjudication) 基准测试 信任审计 推广论证

L2 可信记忆层 (Trusted Memory) 一重心推广后的知识对象 半形式化理论 可

路由策略 (Routing Policy)



✓ 默认路由

完整的分层验证流程

✗ 禁止捷径

探索性输出不能直接
进入可信记忆

⚠ 低风险例外

仅用于已验证的
低风险知识推广

信任模型与晋升门控


核心原则:

- 证据与猜想**严格分离**
- L2 需要**显式人类批准**才能推广
- 探索性输出不会因为 Agent 自信就自动成为可信记忆

来源可信度分级:

等级	来源类型
A	同行评审论文
B	arXiv 预印本
C	博客/技术报告
D	非正式笔记
E	口头声明

晋升门控流程



三条研究通道

	形式理论/推导	玩具模型数值	代码驱动算法
L0 输入	论文、定义、先验声明	基准论文、模型规范、可观测测量	上游代码库、论文、方法
L4 验证	推导审查、证明缺口分析、一致性检查	受控运行、收敛检查、基准比较	复现、信任审计、实现验证
L2 输出	半形式化理论对象、推导笔记、Lean 包	已验证 workflows、基准笔记	可信方法、可复用操作清单
成熟度	活跃	最强	活跃

模型数值是当前最成熟的通道——有基准支持的有限模型研究已能得出有界结论。
形式理论和代码驱动通道仍在持续升级中。

核心原则

- ① **证据优于推测**
Evidence before speculation
- ② **诚实保持不确定性**
Preserve uncertainty honestly
- ③ **验证是一等公民**
Validation is first-class
- ④ **合规 $\neq$ 正确**
Conformance $\neq$ correctness
- ⑤ **协议优于启发式**
Protocol above heuristics

智能保持原则

- 约束边界，而非内部思考
- 每层有局部任务信封
- L2 是可调用的记忆，不是默认答案
- 检查点设在层间交叉处
- 探索窗口必须保持真实

红旗警告

“我可以直接回答这个研究问题”
→ 这正是需要 AITP 的时候

决策点协议：人机双向沟通




AITP 主动暂停的触发条件:

- 范围变更
- 基准不一致
- 晋升门控
- 方法不确定性
- 方向歧义

阻塞语义:

- blocking=true: AITP 暂停等待人类
- blocking=false: 超时后使用默认继续
- 人类始终拥有最终决定权

壳与核：三层架构



实际研究案例：HS-like Chaos Window

研究主题：

Heisenberg 自旋链中的混沌窗口数值探索

AITP 的实际应用：

- L0: 输入论文、模型规范
- L1: 暂定理解——能谱分析
- L3: 探索——候选混沌指标
- L4: 验证——ED 数值基准
- L2: 谨慎推广

显式非结论

不证明算子独立性

不封闭 TDVP/DMRG 可行性

不声称热力学极限定理


关键引用

"This is a protocol-bounded finite-size conclusion, not a thermodynamic-limit theorem."

AITP 的纪律性体现：

- ① 证据链有来源追溯
- ② 信任层次显式标注
- ③ 负面结果保留可见
- ④ 不确定性与结论共存
- ⑤ 人类拥有最终判断权

多仓库架构



数据流: AITP 运行时 → 已验证输出 → TPKN 公共知识后端


关键指标:

- **63** 个里程碑已关闭
(v1.28 → v1.90)
- **367** 个测试通过
- **78+** 个待办事项追踪
- PyPI 包: aitp-kernel
- 跨 3 个 AI 平台运行:
Claude Code / Codex / OpenCode

最新关闭:

v1.90 “假设路径转换权威表面”
(2026-04-12, 单日 18 个里程碑)

成熟度阶梯:



v1.91: 五轴推进框架

轴 1 层内优化Layer-Internal Optimization

轴 2 层间连接优化Inter-Layer Connection

轴 3 层内数据记录Layer-Internal Data Recording

轴 4 全局基础设施 (最高优先级) Global Infrastructure

轴 5 AI Agent 集成AI Agent Integration

v1.91 目标

证明 AITP 在真实物理主题上的实际有效性
从初始想法到一个诚实的有界研究成果，完成端到端验证。

技术层面：

- 源到问题的蒸馏仍有困难
(论文 → 有界研究问题)
- L2 知识图谱仍然稀疏
(仅有少量真实主题填充)
- 自动化形式理论探索仍是实验性的
- 通道特定的第一步智能不足

实践层面：

- 多用户验证尚未测试
- 最终产品包装/分发方案待定
- 协议表面的完整性与
执行覆盖的差距
- HCI (人机交互) 缺口
仍有约 11 项待解决

坦诚声明

AITP 是一个**活跃开发中**的研究工具，不是成熟产品。
其价值主张需要更多真实研究案例来验证。

愿景：约束工程的未来

AITP 的更大图景：

- 不只是物理学的工具——
是一种**研究纪律的模板**
- 可推广到化学、生物、
数学等基础学科
- 核心思想：
 - 协议 > 启发式
 - 工件 > 对话残留
 - 验证 > 流畅
 - 人类 > Agent

AITP 目标形态

Strong Harness

- + Preserved Freedom
- + Evidence Discipline
- + Durable Memory

“不替代研究者——用护栏放大研究能力”

总结

- 🧠 **AITP 不是聊天机器人**——它是一套受治理的研究协议。
从“AI 能写物理文本”到“AI 能纪律性地参与物理研究”
- 📖 **L2 (可信记忆) 是重心**——知识是挣来的，不是给的。
探索性输出不会因为 Agent 自信就自动成为可信记忆
- 🛡️ **约束工程思想**——约束边界，保留自由。
强约束 + 模型自由度 + 显式证据纪律 + 持久记忆

谢谢！欢迎提问。